



您想学习什么？



斯曉宇 ▾

機器學習基石上 (Machine Learning Foundations) --- Mat > 第 8 周 > 作業二

[上一个](#) | [主页](#)


Noise and Error

- ▶ 视频: Noise and Probabilistic Target
17 min
- ▶ 视频: Error Measure
15 min
- ▶ 视频: Algorithmic Error Measure
13 min
- ▶ 视频: Weighted Classification
16 min
- ✔ 测验: 作業二
20 个问题

測驗・40 MIN

作業二

- 提交您的作业
- 截止时间 Dec 30, 3:59 PM CST 答题次数 3/8 hours

-  **收到成绩**
通过条件 75% 或更高

向您的目标更进一步
如果您完成此作业，则完成本课程的可能性增加了 **54%**


再试

成绩
100%

[查看反馈](#)

我们会保留您的最高分数



2. Let "O" = +1, "X" = -1



\therefore "Positive rectangle" hypothesis set 可以 shatter 4 个 inputs ($2^4 = 16$)

\therefore VC-Dimension of the hypothesis set ≥ 4

3.



证 $\text{dvc}(H) = \infty$

将 $2x$ 看作变数.

$$4k+1 \leq 2x \leq 4k+3 \quad \text{此时 } y = -1 \Rightarrow 4k+1 \leq 2x \leq 4k+2 \quad \text{此时 } y = -1$$

↑ "加1"

$$4k-1 \leq 2x \leq 4k+1 \quad \text{此时 } y = 1 \Rightarrow 4k \leq 2x \leq 4k+1 \quad \text{此时 } y = 1$$

由上式我们可以构造一个 α , 当 $y_i = -1$ 时 αx_i 的范围可以通过 "加1" 使得 $h_\alpha(x_i) = -1$

令 $x_i = 4^i$ $\alpha = \sum_{i=1, y_i=-1}^n 4^{-i} \quad (i \geq 1).$

当 $y_j = 1$ 时: $\alpha x_j = 4^j \cdot \sum_{i=1, y_i=-1}^n 4^{-i}$

$$= \sum_{y_i=-1, i < j}^n 4^{j-i} + 0 + \sum_{y_i=-1, i > j}^n 4^{j-i}$$

$$= 4k + 0 + \sum_{y_i=-1, i > j}^n 4^{j-i}$$

$$\therefore 0 \leq \sum_{y_i=-1, i > j}^n 4^{j-i} < \sum_{i=1}^{+\infty} 4^{-i} < \frac{1}{1-4^{-1}} - 1 = \frac{1}{3}$$

$$\therefore 4k \leq \alpha x_j < 4k + \frac{1}{3}$$

$$\therefore y_i = 1 \text{ when } 4k \leq \alpha x_i \leq 4k+1$$

$$\therefore h_\alpha(x_j) = 1 \text{ when } y_j = 1.$$

当 $y_i = -1$ 将在下一页讨论.

接续 problem 3

当 $y_j = -1$ 时:

$$\alpha X_j = 4^j \cdot \sum_{i=1, y_i=-1}^n 4^{-i}$$

$$= \sum_{y_i=-1, i \leq j}^n 4^{j-i} + 1 + \sum_{y_i=-1, i > j}^n 4^{j-i}$$

$$= 4k + 1 + \sum_{y_i=-1, i > j}^n 4^{j-i}$$

$$\therefore 4k + 1 \leq \alpha X_j < 4k + \frac{4}{3}$$

$$\therefore y_i = -1 \text{ when } 4k + 1 \leq \alpha X_i \leq 4k + 2$$

$$\therefore h_\alpha(X_j) = -1 \text{ when } y_j = -1$$

综上所述 $y = 1$ 或 $y = -1$ 时, 都能找到一个 h_α shatter 所有 X

$$\therefore dvc(H) = \infty$$

4. 设 $S_1 = \{\text{dichotomies of } H_1\}$, $S_2 = \{\text{dichotomies of } H_2\}$.

集合中元素数量为 $|S_1|$, $|S_2|$.

$$\therefore |S_1 \cap S_2| \leq |S_1|$$

$$m_{H_1 \cap H_2}(N) = |S_1 \cap S_2|, \quad m_{H_1}(N) = |S_1|$$

如果 $N = dvc(H_1)$

$$m_{H_1 \cap H_2}(N) \leq m_{H_1}(N) = 2^N$$

\therefore 等号(=)成立, $m_{H_1 \cap H_2}(N)$ 有可能 shatter 数量为 $dvc(H_1)$ 的 inputs.

如果 $N = dvc(H_1) + 1$

$$m_{H_1 \cap H_2}(N) \leq m_{H_1}(N) < 2^N$$

$\therefore m_{H_1 \cap H_2}(N)$ 不能 shatter 数量为 $dvc(H_1) + 1$ 的 inputs, 小于号(<)成立.

$$\therefore dvc(H_1 \cap H_2) \leq dvc(H_1).$$

法2. 反证法.

假设 $dvc(H_1 \cap H_2) > dvc(H_1)$

$dvc(H_1 \cap H_2)$ 代表 $H_1 \cap H_2$ 能 shatter 最多 $|H_1 \cap H_2|$ 个 inputs., $dvc(H_1)$ 代表 H_1 能 shatter 最多

而根据集合关系 $H_1 \cap H_2 \subseteq H_1 \Rightarrow |H_1 \cap H_2| \leq |H_1|$

$|H_1|$ 个 inputs.

$\therefore dvc(H_1 \cap H_2)$ 无法 shatter 多于 $|H_1|$ 个 inputs.

$\therefore dvc(H_1 \cap H_2) > dvc(H_1)$ 不成立

$$\therefore dvc(H_1 \cap H_2) \leq dvc(H_1).$$

5. $m_{H_1}(N) = m_{H_2}(N) = N-1$

\therefore 当 $H_1 \cup H_2$ 在 $N-1$ 个区间内时

会产生 2 种不同的 dichotomies

另外在 2 端会产生全为 "0" 或全为 "x"

$\therefore m_{H_1 \cup H_2}(N) = 2(N-1) + 2 = 2N$


当 $N=1$ 时 $m_{H_1 \cup H_2} = 2N = 2 = 2^1$ 可以 shatter 1 个 input

当 $N=2$ 时 $m_{H_1 \cup H_2} = 2N = 4 = 2^2$ 可以 shatter 2 个 inputs

当 $N=3$ 时 $m_{H_1 \cup H_2} = 2N = 6 < 2^3 = 8$ 不可以 shatter 3 个 inputs

$\therefore \text{dvc}(H_1 \cup H_2) = 2.$

6.



$$P(y|x) = \begin{cases} 0.8 & y = f(x) \\ 0.2 & y \neq f(x) \end{cases}$$

$f(x) = \tilde{s}(x) + \text{noise}$ where $\tilde{s}(x) = \text{sign}(x)$

$$-1 \leq x \leq 0 \begin{cases} 0.8 & y = -1 \\ 0.2 & y = 1 \end{cases} \quad 0 < x \leq 1 \begin{cases} 0.8 & y = 1 \\ 0.2 & y = -1 \end{cases}$$

$$E_{\text{out}}(h_{s,\theta}) = \int_{-1}^1 P(x) \cdot E_{y \sim P(y|x)} [h_{s,\theta}(x) \neq y] dx$$

$$= \frac{1}{2} \left[\int_{-1}^0 E_{y \sim P(y|x)} [h_{s,\theta}(x) \neq y] dx + \int_0^1 E_{y \sim P(y|x)} [h_{s,\theta}(x) \neq y] dx \right]$$

$$= \frac{1}{2} \left[\int_{-1}^0 0.8 [h_{s,\theta}(x) \neq -1] + 0.2 [h_{s,\theta}(x) \neq 1] dx + \right.$$

$$\left. \int_0^1 0.8 [h_{s,\theta}(x) \neq 1] + 0.2 [h_{s,\theta}(x) \neq -1] dx \right]$$

假设 $s = +1$ $h_{s,\theta}(x) = \text{sign}(x - \theta)$

$$\theta < 0: E_{\text{out}}(h_{s,\theta}) = \frac{1}{2} \left[\int_{-1}^{\theta} 0.2 dx + \int_{\theta}^0 0.8 dx + \int_0^1 0.2 dx \right]$$

$$= \frac{1}{2} [0.2(\theta - (-1)) + 0.8(0 - \theta) + 0.2(1 - 0)]$$

$$= \frac{1}{2} [0.2\theta + 0.2 - 0.8\theta + 0.2]$$

$$= -0.3\theta + 0.2$$

$$\theta \geq 0: E_{\text{out}}(h_{s,\theta}) = \frac{1}{2} \left[\int_{-1}^0 0.2 dx + \int_0^{\theta} 0.8 dx + \int_{\theta}^1 0.2 dx \right]$$

$$= \frac{1}{2} [0.2(0 - (-1)) + 0.8(\theta - 0) + 0.2(1 - \theta)]$$

$$= \frac{1}{2} [0.2 + 0.8\theta + 0.2 - 0.2\theta]$$

$$= 0.3\theta + 0.2$$

假设 $s = -1$ $h_{s,\theta}(x) = -\text{sign}(x - \theta)$

$$\theta < 0: E_{\text{out}}(h_{s,\theta}) = \frac{1}{2} \left[\int_{-1}^{\theta} 0.8 dx + \int_{\theta}^0 0.2 dx + \int_0^1 0.8 dx \right]$$

$$= \frac{1}{2} [0.8(\theta - (-1)) + 0.2(0 - \theta) + 0.8(1 - 0)]$$

$$= \frac{1}{2} [0.8\theta + 0.8 - 0.2\theta + 0.8]$$

$$= 0.3\theta + 0.8$$

下一页

接續


$$S = -1 \quad h_{s,\theta}(x) = -\text{sign}(x - \theta)$$

$$\begin{aligned} \theta \geq 0 \quad E_{\text{out}}(h_{s,\theta}) &= \frac{1}{2} \left[\int_{-1}^0 0.8 dx + \int_0^\theta 0.2 dx + \int_\theta^1 0.8 dx \right] \\ &= \frac{1}{2} [0.8(0 - (-1)) + 0.2(\theta - 0) + 0.8(1 - \theta)] \\ &= \frac{1}{2} [0.8 + 0.2\theta + 0.8 - 0.8\theta] \\ &= -0.3\theta + 0.8 \end{aligned}$$

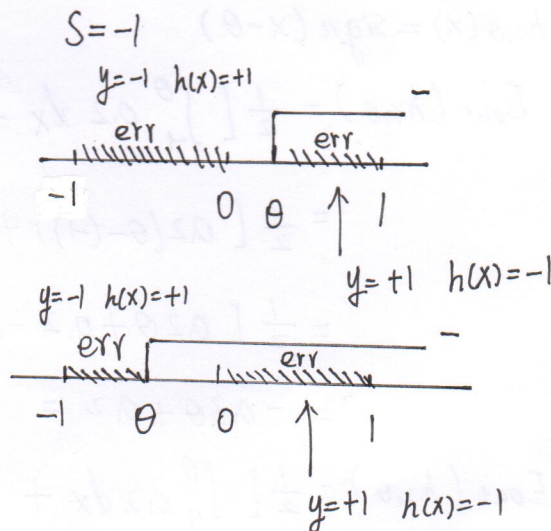
綜上可得 $E_{\text{out}}(h_{s,\theta}) = 0.5 + 0.3S(|\theta| - 1)$

方法二.

由 Coursera 第1題可知 $E_{\text{out}} = \lambda \mu + (1 - \lambda)(1 - \mu)$, where $\lambda = 0.8$, μ 為沒有 noise 的錯誤率



$$\mu_{S=+1} = \frac{|\theta|}{2}$$



$$\mu_{S=-1} = 1 - \frac{|\theta|}{2}$$


$$\begin{aligned} \mu_{s,\theta} &= 0.5(S+1) \times 0.5|\theta| - 0.5(S-1)(1 - 0.5|\theta|) \\ &= 0.5S|\theta| - 0.5S + 0.5 \end{aligned}$$

$$\begin{aligned} E_{\text{out}}(h_{s,\theta}) &= \lambda \mu_{s,\theta} + (1 - \lambda)(1 - \mu_{s,\theta}) \\ &= 0.5 + 0.3S(|\theta| - 1) \end{aligned}$$

7.

通過觀察直方圖， $E_{in}-E_{out}$ 近似高斯分佈，其數值基本位於區間 $[-0.2, 0.1]$ 之間。當 training data 為 20 的時候， $E_{in}-E_{out}$ 的差值多為負值，說明 E_{in} 通常小於 E_{out} 。我們知道在 20% noise 的情況下，真實的 avg E_{in} 和 E_{out} 都約為 0.2，而當前結果顯示 E_{in} 最小的 hypothesis 不一定能保證 E_{out} 最小，且 E_{in} 和 E_{out} 仍不夠接近。

```
Average_E_in = 0.165900  
Average_E_out = 0.254686  
Ein-Eout= -0.08878643295061384
```




8.

在 training data 擴增到 2000 的情況下，我們可以很明顯觀察到 $E_{in}-E_{out}$ 呈現高斯分佈，其差值基本位於 $[-0.01, 0.01]$ 之間。在訓練資料增加的情況下，VC bound 限制了 E_{in} 與 E_{out} 的差距，同時 avg E_{in} 與 E_{out} 在此情況下更接近真實值。滿足了機器可以學習的條件，即 $E_{in} \approx 0$ ，且 $E_{in} \approx E_{out}$ 。

Average E_{in} = 0.199878


Average E_{out} = 0.200634

$E_{in}-E_{out}$ = -0.0007558015278006092



9.

假设在二维空间中 $d=2$, $S \subseteq \{[0,0]^T, [0,1]^T, [1,0]^T, [1,1]^T\}$



$t = [t_1, t_2]^T$ 把二维平面划分为4个区域

对任意点 $x = [x_1, x_2]^T$ 根据 x_1, x_2 与 t_1, t_2 的大小关系都可以被划分到4个区域之一

\therefore 对于 $d=2$ (二维平面), H 可以 shatter 最多 $4 (2^d, \text{ where } d=2)$ 个点,

或许可以借此推论, H on \mathbb{R}^d 可以 shatter 最多 2^d 个点,